

Open source vs modelos propietarios.

Tener criterio, evaluar riesgos y
procedimientos para ver qué encaja mejor.

¿Qué elegirían para analizar contratos internos?

ChatGPT

Copilot

Claude

Modelo local

Lo hago a mano

Depende.

Cuatro palabras que se mezclan

Antes de comparar opciones, alineemos vocabulario. No es lo mismo el modelo, la app que usás, ni cómo lo integrás en código.

Modelo

Red entrenada con pesos y arquitectura (GPT, Llama, Claude...)

Plataforma

Producto listo para usar (ChatGPT, Copilot, Cursor)

API

Interfaz para invocar el modelo desde código o sistemas

Herramienta

Interfaz de usuario sobre el modelo (chat, asistente)

**No elegís solo
el modelo.**

Elegís el sistema.

¿Qué tan **abierto** es el modelo?

Sobre licencia y pesos: si podés verlos, descargarlos o adaptarlos.

Propietario cerrado

Pesos privados. Solo acceso por API o suscripción

GPT-5.x, Claude, Gemini

Open weights

Pesos descargables, con condiciones de licencia

Llama 4, Mistral, Qwen, DeepSeek

Modelo custom

Fine-tuned o entrenado con datos propios. Pesos no públicos

Adaptación de Llama, modelo interno

Open source real

Pesos + receta de entrenamiento + datos abiertos

OLMo, modelos de investigación

¿Dónde corren tus datos?

El mismo Llama puede estar en tu laptop o en la nube: la apertura del modelo y el despliegue son decisiones independientes.

+ CONTROL / + PRIVACIDAD

+ CONVENIENCIA / + EXPOSICIÓN

Tu máquina	Servidor on-prem	Hosteado por tercero	Nube privada	API del proveedor	App pública (consumer)
Laptop o workstation con Ollama / LM Studio. Nada sale del equipo.	GPU propia sirviendo al equipo con vLLM, dentro de tu red.	Open weights en infra compartida: Groq, Together, Replicate.	Tu cuenta en la nube, red privada y políticas tuyas.	Endpoint con contrato y DPA (GPT-5.x, Claude).	ChatGPT free, apps sueltas. Sin garantías de datos.
CONTROL Alto	CONTROL Alto	CONTROL Medio	CONTROL Medio	CONTROL Bajo	CONTROL Mínimo
PRIVACIDAD Alta	PRIVACIDAD Alta	PRIVACIDAD Media	PRIVACIDAD Alta	PRIVACIDAD Variable	PRIVACIDAD Baja
ESFUERZO Bajo	ESFUERZO Alto	ESFUERZO Bajo	ESFUERZO Medio	ESFUERZO Bajo	ESFUERZO Nulo

Lo que suele **confundir**

Free ≠ enterprise

ChatGPT free y ChatGPT Enterprise no tienen las mismas reglas de datos ni retención

Licencia con letra chica

Podés descargar Llama o Mistral y aun así tener restricciones comerciales

Local sigue costando

Mantenimiento, actualizaciones, desgaste del hardware, costo de oportunidad... Son costos arraigados al local y hacen que no sea cero.

Hosteado ≠ tuyo

Groq o Together corren open weights, pero tus datos pasan por su infra

Comparativa: calidad y costo

	PROPIETARIO	LOCAL / OPEN	HÍBRIDO
Calidad	Tope en tareas complejas	La brecha se achicó en 2026 (Llama, Qwen, DeepSeek)	Razonás en el mejor modelo, el dato lo preparás local
Privacidad	Según contrato (DPA)	Datos en tu perímetro	Anonimizás local, mandás solo lo limpio
Costo al arrancar	Bajo: API o suscripción	Alto: GPU y setup	Medio: API más una capa local
Costo a escala	Sube con el volumen	Se amortiza a volumen alto	Lo barato local, lo crítico por API
Tiempo de implementación	Rápido	Lento	Medio

La curva de costo se cruza: la API arranca barata y se encarece a escala; lo propio arranca caro y se amortiza a volumen sostenido.

Comparativa: operación

PROPIETARIO


LOCAL / OPEN

Mantenimiento	Del proveedor	Propio
Escalabilidad	Gestionada por el vendor	La construís vos
Gobernanza	Políticas del proveedor	Políticas internas
Soporte	Contrato comercial (SLA)	Comunidad o consultoría
Trazabilidad	Logs del proveedor	Logs propios

A volumen alto y sostenido, lo propio puede salir más barato que la API.

¿API o infraestructura propia?

A bajo volumen gana la API. A volumen sostenido, lo propio se amortiza.



VOLUMEN MENSUAL

28.571 REQ

API

\$857

por mes

LOCAL

\$857

por mes

A 29k req/mes, la API sale **\$0** más barata por mes.

Supuestos: API \$0.03/req · local \$800/mes fijos + \$0.002/req. El costo local NO incluye el tiempo de operar el modelo.

¿Qué modelo usar para cada tarea?

EN TU MÁQUINA / OPEN

API O SUSCRIPCIÓN

Razonamiento complejo	DeepSeek V4, Qwen 3.6 grande	Claude Opus, GPT-5.x, Gemini Pro
Coding y agentes	Qwen 3.6 Coder, Devstral	Claude Opus, GPT-5.x
Clasificar / extraer	Qwen chico, Gemma 4, Phi	Gemini Flash, GPT-5 mini
Resúmenes simples	Llama 4, Mistral	Gemini Flash, Claude Haiku
Multimodal / visión	Qwen-VL, Gemma 4	Gemini, GPT-5.x
Generar imágenes	FLUX, Stable Diffusion	GPT Image, Imagen, Midjourney
Embeddings (RAG)	nomic-embed, bge	OpenAI, Voyage, Cohere

CÓMO CORRERLO EN TU MÁQUINA

Ollama / LM Studio: probar y usar en tu PC, sin montar servidor.

vLLM: servir el modelo en red para tu equipo o producción (más setup, más escala).

CÓMO USARLO EN LA EMPRESA

Suscripción: ChatGPT, Copilot, Claude (app o plan de equipo).

API en tu cloud: Azure OpenAI, Bedrock, Vertex (mismo modelo, tus políticas de datos).

¿Suficientemente bueno?

Tarea: clasificar tickets de soporte. Mismo set de casos para los tres modelos.

▶ CORRER DE NUEVO



CASO · CATEGORÍA ESPERADA	GEMMA 4 63%	QWEN 3.6 88%	GPT-5 MINI 100%
No puedo entrar a mi cuenta desde ayer Acceso	✓	✓	✓
Me cobraron dos veces el mismo plan Facturación	✓	✓	✓
¿Tienen descuento para equipos grandes? Ventas	✗	✓	✓
La app se cierra sola al subir un archivo Bug técnico	✓	✓	✓
Quiero cancelar pero me siguen facturando Facturación	✗	✗	✓
El informe exportado sale con datos de otro cliente Bug técnico	✓	✓	✓
¿Pueden mandarme una factura A a nombre de mi empresa? Facturación	✓	✓	✓
Necesito una demo antes de contratar el plan anual Ventas	✗	✓	✓

UMBRAL MÍNIMO ACEPTABLE 85%

No buscás el mejor: buscás el más barato que cumpla tu barra.

VEREDICTO

Qwen 3.6 (local)

Es el más barato que supera el 85%. Pagar por uno mejor no cambia el resultado de tu tarea.

\$ ●● GPU propia ⚡ medio

Elegí contra tus casos, no por el leaderboard ni por la fama del modelo.

¿Cuándo usar **modelos propietarios**?

Razonamiento complejo donde importa la calidad

Producto listo, sin montar infraestructura

Integraciones con M365, Google, Slack, etc.

Necesitás salir rápido a producción

Datos no sensibles, o con acuerdo de tratamiento (DPA)

Sin equipo que opere modelos (MLOps)

¿Cuándo usar modelos locales / open?

Datos sensibles: PII, salud, legal, financiero

Los datos no deberían salir de tu red o infraestructura

Querés menos dependencia de un proveedor externo

Tareas acotadas: clasificación, extracción, etiquetado

Resúmenes simples con un modelo chico y económico

Pruebas internas con control estricto de acceso

¿Cuándo conviene armar procesos híbridos?

- Necesitás calidad de frontera pero los datos no pueden ir crudos a una API
- La regulación exige control local y aun así querés razonamiento avanzado
- Un modelo solo no alcanza: anonimizar o recuperar local, razonar en API
- Hay que auditar entradas y salidas, con revisión humana antes de actuar
- Tareas simples en volumen conviene local; las críticas, en modelo propietario
- La política prohíbe SaaS consumer pero el equipo igual necesita IA

Riesgos a evaluar

Fuga de datos

Prompts, logs y retención del proveedor

Entrenan con tus datos

Revisá opt-out y tier enterprise

Alucinación

Inventa con seguridad: crítico en legal, salud, finanzas

Lock-in

Prompts, evals e integraciones atadas a un proveedor

Deprecación

Te cambian o retiran la versión que tenías en producción

Compliance

Datos personales, normativa local y sectorial

Flujo híbrido en acción

1. Detectar qué no debe salir del perímetro

2. Anonimizar en tu entorno y guardar el mapa local

3. Enviar solo la versión sin PII al modelo propietario

4. Re-hidratar la respuesta con el mapa que quedó local

Anonimización local

👁 1 • DETECTAR

→

🔒 2 • ANONIMIZAR

→

✉ 3 • ENVIAR

→

🔗 4 • RE-HIDRATAR

MARCÁ QUÉ TIPOS DE DATO ENMASCARAR:

Nombre: 3

CUIT: 1

DNI: 2

Dirección: 1

Email: 2

Teléfono: 2

Monto: 2

🛡 EXPOSICIÓN ALTA

👁 DATOS QUE NO DEBERÍAN SALIR DEL PERÍMETRO

CONTRATO DE SERVICIOS - CONFIDENCIAL

Entre Acme Corp S.A. (CUIT 30-71234567-8) y el Sr. Juan Carlos Pérez (DNI 28.456.789), domiciliado en Av. Corrientes 1234, CABA.

Contacto: juan.perez@empresa.com.ar • Tel: +54 11 4567-8901

Cláusula 3 - Honorarios: USD 125.000 anuales + bono de USD 45.000.

Cliente final: María González (DNI 35.678.901), maria.gonzalez@cliente.com, tel 011-5555-4321.

El riesgo no es usar IA, sino enviar **datos sensibles sin anonimizar**. El mapa para revertir vive solo en tu equipo.

Anonimización local

👁 1 · DETECTAR → 🗝 2 · ANONIMIZAR → 📧 3 · ENVIAR → 🔗 4 · RE-HIDRATAR

🛡 EXPOSICIÓN ——— BAJA

CLICK PARA AGREGAR O QUITAR: **Nombre: 3** **CUIT: 1** **DNI: 2** **Dirección: 1** **Email: 2** **Teléfono: 2** **Monto: 2**

• ORIGINAL · QUEDA LOCAL	🗝 ANONIMIZADO · APTO PARA SALIR
CONTRATO DE SERVICIOS - CONFIDENCIAL	CONTRATO DE SERVICIOS - CONFIDENCIAL
Entre Acme Corp S.A. (CUIT 30-71234567-8) y el Sr. Juan Carlos Pérez (DNI 28.456.789), domiciliado en Av. Corrientes 1234, CABA .	Entre Acme Corp S.A. (CUIT [CUIT_1]) y el [NOMBRE_2] ([DNI_1]), [DIRECCION_1] .
Contacto: juan.perez@empresa.com.ar · Tel: +54 11 4567-8901	Contacto: [EMAIL_1] · Tel: +54 11 4567-8901
Cláusula 3 - Honorarios: USD 125.000 anuales + bono de USD 45.000 .	Cláusula 3 - Honorarios: [MONTO_1] anuales + bono de [MONTO_2]
Cliente final: María González (DNI 35.678.901), maria.gonzalez@cliente.com , tel 011-5555-4321 .	Cliente final: [NOMBRE_3] ([DNI_2]), [EMAIL_2] , tel [TEL_2] .

Anonimización local

1 • DETECTAR → 2 • ANONIMIZAR → 3 • ENVIAR → 4 • RE-HIDRATAR

EXPOSICIÓN — BAJA

CLICK PARA AGREGAR O QUITAR: Nombre: 3 CUIT: 1 DNI: 2 Dirección: 1 Email: 2 Teléfono: 2 Monto: 2

MAPA LOCAL • TOKEN ↔ ORIGINAL

[NOMBRE_1] → Entre Acme Corp

[CUIT_1] → 30-71234567-8

[NOMBRE_2] → Sr. Juan Carlos Pérez

[DNI_1] → DNI 28.456.789

[DIRECCION_1] → domiciliado en Av. Corrientes 1234, C...

[EMAIL_1] → juan.perez@empresa.com.ar

[TEL_1] → Tel: +54 11 4567-8901

[MONTO_1] → USD 125.000

[MONTO_2] → USD 45.000.

[NOMBRE_3] → María González

[DNI_2] → DNI 35.678.901

AL MODELO EXTERNO

CONTRATO DE SERVICIOS - CONFIDENCIAL[NOMBRE_1]
S.A. (CUIT [CUIT_1]) y el [NOMBRE_2] ([DNI_1]),
[DIRECCION_1].
Contacto: [EMAIL_1] • [TEL_1]Cláusula 3 -
Honorarios: [MONTO_1] anuales + bono de
[MONTO_2]
Cliente final: [NOMBRE_3] ([DNI_2]), [EMAIL_2],
tel [TEL_2].

Anonimización local

1 · DETECTAR

→

2 · ANONIMIZAR

→

3 · ENVIAR

→

4 · RE-HIDRATAR

CLICK PARA AGREGAR O QUITAR: Nombre: 3 CUIT: 1 DNI: 2 Dirección: 1 Email: 2 Teléfono: 2 Monto: 2

EXPOSICIÓN

BAJA

RESPUESTA DEL MODELO

La cláusula 3 fija honorarios de [MONT0_1] anuales para [NOMBRE_1], con un bono de [MONT0_2]. Sugiero aclarar la moneda y el plazo de pago antes de firmar.

RE-HIDRATADA EN TU EQUIPO

La cláusula 3 fija honorarios de USD 125.000 anuales para
Entre Acme Corp, con un bono de USD 45.000..
Sugiero aclarar la moneda y el plazo de pago antes de firmar.

¿Qué estrategia conviene?

AJUSTÁ CADA CRITERIO DE TU CASO →

TIPO DE DATO

Público / genérico

Interno no sensible

PII / datos personales

Secreto comercial / legal

RIESGO DEL ERROR

Bajo (borrador)

Medio (revisión humana)

Alto (decisión crítica)

NECESIDAD DE CALIDAD

Clasificación / extracción

Resumen / redacción

Razonamiento complejo

FRECUENCIA DE USO

Ocasional

Diario

Alto volumen

PRIVACIDAD

Sin restricción

Política interna estricta

Regulatorio (GDPR, etc.)

TRAZABILIDAD

Opcional

Auditoría requerida

PRESUPUESTO

Mínimo / capex limitado

Moderado (API OK)


Alto (velocidad > costo)

● RECALCULA EN VIVO

🕒 ESTRATEGIA RECOMENDADA

Híbrido

Anonimizar en tu entorno, razonar con modelo propietario, revisar humano y auditar.



POR QUÉ

- Tipo de dato → Local / open weights
- Riesgo del error → Híbrido
- Necesidad de calidad → Modelo propietario
- Frecuencia de uso → Modelo propietario

Trampas comunes

✗ “Corremos local para estar seguros”, pero el equipo pega el mismo doc en ChatGPT

✗ “Ya lo anonimizamos”, pero el agente tiene web search y filtra el contexto

✗ “Elegimos open source” sin leer la licencia comercial

✗ “Fine-tuneamos” con 50 ejemplos cuando alcanzaba con RAG

✗ “Un solo modelo para todo” sin evaluar por tipo de tarea

✗ “Local es gratis” sin contar GPU, operación ni mantenimiento

Armá tu caso

Elegí un caso real y completá:

☐ Caso de uso concreto

☐ Qué datos entran en juego

☐ Qué pasa si la IA se equivoca

☐ Estrategia elegida (propietario, local, híbrido)

☐ Dónde entra la revisión humana

☐ Qué queda registrado para auditoría

☐ Cómo medís que funciona

☐ Plan B si el proveedor cambia o falla

**El problema no es
usar IA.
Es usarla sin criterio.**